


МАГОЛЕГО  
Линейная алгебра в приложениях  
Семинар 11

Д. И. Пионтковский, И. К. Козлов  
(ВШЭ)

9 апреля 2021

# Литература

 Шевцов Г.С.,  
*Линейная алгебра: теория и прикладные аспекты,*  
Глава 10. Итерационные методы,

# Метод итераций

- 1 Метод итераций.
- 2 Приведение к виду, удобному для итераций.
- 3 Метод Зейделя.
- 4 Добавления. Другие примеры методы итераций.

# Семинар 11

Решение уравнения

$$x = Px + c$$

методом итераций:

$$x^{(n+1)} = Px^{(n)} + c.$$

## Семинар 11

**Утв 1.** Процесс сходится при любом начальном  $x^{(0)} \Leftrightarrow$  спектральный радиус  $\rho(P) < 1$ .

**Утв. 2** Верна оценка:

$$\left| x - x^{(k)} \right| \leq \frac{\|P\|^k}{1 - \|P\|} |x^{(1)} - x^{(0)}|.$$

Если  $\|P\| < 1$ , то метод итераций сходится.

Матричную норму можно брать любой.

## Семинар 11

Применим оценку

$$\left| x - x^{(k)} \right| \leq \frac{\|P\|^k}{1 - \|P\|} |x^{(1)} - x^{(0)}|.$$

- Если  $x^{(0)} = 0$ , то  $x^{(1)} = c$  и

$$\left| x - x^{(k)} \right| \leq \frac{\|P\|^k}{1 - \|P\|} |c|.$$

- Если  $x^{(0)} = c$ , то  $x^{(1)} = Pc + c$  и

$$\left| x - x^{(k)} \right| \leq \frac{\|P\|^{k+1}}{1 - \|P\|} |x^{(0)}|.$$

## Семинар 11

**Задача.** Методом итераций решить систему

$$\begin{cases} 10x_1 + 2x_2 + x_3 = 10, \\ x_1 + 10x_2 + 2x_3 = 12, \\ x_1 + x_2 + 10x_3 = 8. \end{cases}$$

**Решение.** Переходим к системе:

$$\begin{cases} x_1 = 1 - 0,2x_2 - 0,1x_3, \\ x_2 = 1,2 - 0,1x_1 - 0,2x_3, \\ x_3 = 0,8 - 0,1x_1 - 0,1x_2. \end{cases}$$

## Семинар 11

Матрица

$$P = \begin{pmatrix} 0 & -0,2 & -0,1 \\ -0,1 & 0 & -0,2 \\ -0,1 & -0,1 & 0 \end{pmatrix}.$$

Заметим, что

$$\|P\|_1 = \max(0,2; \quad 0,3; \quad 0,3) = 0,3 < 1,$$

поэтому метод итераций сойдётся.

Норму  $\|P\|_1$  легко считать (сумма модулей по столбцам).

За начальное приближение можно взять  $x^{(0)} = c$ :

$$x_1^{(0)} = 1, \quad x_2^{(0)} = 1,2, \quad x_3^{(0)} = 0,8.$$



## Семинар 11

Решение

$$x \approx x^{(5)} \approx (0,737; \quad 1,001; \quad 0,626)$$

Оценка погрешности

$$\left| x - x^{(5)} \right| \leq \frac{\|P\|^6}{1 - \|P\|} \left| x^{(0)} \right| = \frac{(0,3)^6}{0,7} 3 \leq 0,001.$$

# Приведение к виду, удобному для итераций

1 Метод итераций.

2 Приведение к виду, удобному для итераций.

3 Метод Зейделя.

4 Добавления. Другие примеры методы итераций.

## Семинар 11

**Задача.** Привести к виду, удобному для итераций

$$Ax = b.$$

**Случай-1.** Пусть  $A = A^T$  и есть диагональное преобладание:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|.$$

Диагональные элементы больше суммы модулей остальных элементов в своей строке.

Выражаем из  $i$ -того уравнения  $x_i$ :

$$\begin{cases} x_1 = \dots, \\ x_2 = \dots, \\ \dots \end{cases}$$

## Семинар 11

**Задача.** Привести к виду, удобному для итераций

$$Ax = b.$$

**Случай-2.** Пусть  $A = A^T$  и все собственные числа  $\lambda_i > 0$ .

Берём

$$P = E - \tau A, \quad \bar{b} = \tau b,$$

где

$$\tau = \frac{2}{\lambda_{\min} + \lambda_{\max}}.$$

Затем решаем методом итераций

$$x_{k+1} = Px_k + \bar{b}.$$

## Семинар 11

**Случай-3.** Если  $A \neq A^T$ , то переходим к системе

$$A^T A x = A^T b.$$

Далее поступаем так же, как и для симметричной матрицы.

## Семинар 11

На практике находить

$$\tau = \frac{2}{\lambda_{\min} + \lambda_{\max}}$$

иногда затруднительно. Поэтому берут

$$\tau = \frac{2}{\sigma},$$

где  $\sigma$  больше какой-нибудь из просто вычисляемых матричных норм

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad \|A\|_\infty = \max_i \sum_j |a_{ij}|.$$

# Метод Зейделя

- 1 Метод итераций.
- 2 Приведение к виду, удобному для итераций.
- 3 Метод Зейделя.
- 4 Добавления. Другие примеры методы итераций.

## Семинар 11

### Метод Зейделя.

Пусть мы решаем уравнение  $Ax = y$ . Разложим

$$(L + D)\vec{x} = -U\vec{x} + \vec{b},$$

где  $D$  — диагональная, а  $L$  и  $U$  — строго нижнетреугольная и верхнетреугольная матрицы. Итерационный процесс в методе Гаусса — Зейделя:

$$(L + D)\vec{x}^{(k+1)} = -U\vec{x}^{(k)} + \vec{b}.$$



## Семинар 11

По сути это тот же метод итераций:

$$(\mathbf{L} + \mathbf{D})\vec{x}^{k+1} = -\mathbf{U}\vec{x}^k + \vec{b}$$

эквивалентная

$$\vec{x}^{k+1} = (\mathbf{L} + \mathbf{D})^{-1}\vec{b} - (\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}\vec{x}^k.$$

Так что метод сходится, если

$$\|(\mathbf{L} + \mathbf{D})^{-1}\mathbf{U}\| < 1.$$

## Другие примеры методы итераций

- 1 Метод итераций.
- 2 Приведение к виду, удобному для итераций.
- 3 Метод Зейделя.
- 4 Добавления. Другие примеры методы итераций.

## Семинар 11

Пусть  $A = A^T$ .

Методом итераций можно находить собственные значения  $A$ .

Возьмём базис  $e_i$  из собственных векторов

$$Ae_i = \lambda_i e_i, \quad |\lambda_1| \geq |\lambda_2| \geq \dots$$

Тогда

$$A^k(e_1, \dots, e_n) = (\lambda_1^k e_1, \dots, \lambda_n^k e_n) = \lambda_1^k \cdot \left( e_1, \left( \frac{\lambda_2}{\lambda_1} \right)^k e_2, \dots, \left( \frac{\lambda_n}{\lambda_1} \right)^k e_n \right).$$

$$\left( \frac{\lambda_j}{\lambda_1} \right)^k \rightarrow 0, \text{ если } \left| \frac{\lambda_j}{\lambda_1} \right| < 1.$$

## Семинар 11

Берём

$$v_{k+1} = \frac{Av_k}{\|Av_k\|}.$$

В пределе получаем собственный вектор

$$Av = \lambda v,$$

после этого переходим к ортогональному дополнению

$$(w, v) = 0.$$

## Семинар 11

**Утверждение.** Градиент — направление наибольшего роста функции.

Дана функция  $f(x^1, \dots, x^n) : \mathbb{R}^n \rightarrow \mathbb{R}$ . Её градиент:

$$\left( \frac{\partial f}{\partial x^1}, \dots, \frac{\partial f}{\partial x^n} \right).$$

Производная по направлению  $v$  (в нуле):

$$\frac{d}{dt} f(tv^1, \dots, tv^n) = \sum_{i=1}^n \frac{\partial f}{\partial x^i} v^i = (\operatorname{grad} f, v).$$

Напомним, что скалярное произведение — произведение длин на косинус угла между векторами:

$$(u, v) = |u||v| \cos \varphi$$

Наибольшее скалярное произведение — если векторы сонаправлены.

# Семинар 11

## Линейная регрессия.

Даны векторы  $x_i \in \mathbb{R}^n$  и предсказываемые значения  $y_i$ . Пусть мы хотим максимально точно приблизить

$$y_i = (x_i, \omega).$$

**Вариант-1.** Точное решение (через псевдообратную матрицу)

$$\omega = X^+ y.$$

## Семинар 11

**Вариант-2.** Градиентный спуск.

Мы минимизируем функцию потерь:

$$L(\omega, X, y) = \frac{1}{n} \sum_i (y_i - (x_i, \omega))^2.$$

Метод итераций:

$$\omega \rightarrow \omega - \alpha \frac{\partial}{\partial \omega} L.$$

*Аналогично для логистической регрессии.*

**Вариант-3.** Максимизация правдоподобия.

$$y_i = (x_i, \omega) + \varepsilon,$$

где шум  $\varepsilon$  нормально распределён  $N(0, \sigma^2)$ , т.е.

$$p(y|x, \omega) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - (x, \omega))^2}{2\sigma^2}\right).$$



## Семинар 11

Максимизация функции правдоподобия

$$Likelihood(y, X, \omega) = \prod_i p(y_i | x_i, \omega) = \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - (x_i, \omega)^2)}{2\sigma^2}\right)$$

эквивалентна методу наименьших квадратов

$$\min_{\omega} (y_i - (x_i, \omega)^2).$$

Это легко увидеть, взяв логарифм функции правдоподобия.

*Вероятностный подход/Байесовские методы.*